

נתון:  $Y$  משתנה מקרי בדיד, המכונה באופן זה:

$$Y = \begin{cases} 1 & P \\ -1 & 1-P \end{cases}$$

$$Y \sim \text{Bernoulli}(P)$$

$$f(x | Y=1) = \lambda_1 \exp(-\lambda_1 x)$$

$$f(x | Y=-1) = \lambda_2 \exp(-\lambda_2 x)$$

נניח כי  $X_1, \dots, X_n$  הם תצפיות בלתי תלויות:

$$\prod_{t=1}^n f(x_t; \theta) = \prod_{t=1}^n \sum_{i \in \{-1, 1\}} f(x_t | Y=i; \theta) \cdot P(Y=i)$$

כדי לחשב את  $\log$  הנכס, נשתמש ב- EM Step

המשקל  $Q$  של  $\text{Auxiliary}$  -  $Q(\theta, \theta_0)$

$$Q(\theta, \theta_0) = \sum_{t=1}^n \sum_{i \in \{-1, 1\}} P(Y_t=i | x_t; \theta_0) \log P(x_t, Y_t=i; \theta)$$

נחשב את  $Q$  עבור  $i=1$  ו-  $i=-1$ :

$$P(Y_t=i | x_t; \theta_0) = \frac{f(x_t | Y_t=i; \theta_0) \cdot P(Y_t=i)}{f(x_t)}$$

$$= \begin{cases} \frac{\lambda_1 \exp(-\lambda_1 x_t) \cdot P}{P \lambda_1 \exp(-\lambda_1 x_t) + (1-P) \lambda_2 \exp(-\lambda_2 x_t)} & i=1 \\ \frac{\lambda_2 \exp(-\lambda_2 x_t) \cdot (1-P)}{P \lambda_1 \exp(-\lambda_1 x_t) + (1-P) \lambda_2 \exp(-\lambda_2 x_t)} & i=-1 \end{cases}$$

נניח כי  $\omega_{t1}$  ו-  $\omega_{t2}$  הם המשקלים:

כאשר נתון את הביטוי הנ"ל:

$$\log p(x_t, y_t=i; \theta) = \log p(y_t=i; \theta) p(x_t | y_t=i; \theta) =$$

$$= \begin{cases} \log p + \log \lambda_1 + (-\lambda_1 x_t) & i=1 \\ \log(1-p) + \log \lambda_2 - \lambda_2 x_t & i=-1 \end{cases}$$

כאשר נציב ב-Q את הסכום הנ"ל:

$$\sum_{t=1}^n w_{t1} (\log p + \log \lambda_1 - \lambda_1 x_t) + w_{t2} (\log(1-p) + \log \lambda_2 - \lambda_2 x_t)$$

M Step

נציב את p ו-Q ונחשב את הפונקציה Q.

$$\frac{\partial}{\partial p} \sum_{t=1}^n w_{t1} \log p + w_{t2} \log(1-p) = \sum_{t=1}^n w_{t1} \cdot \frac{1}{p} - w_{t2} \cdot \frac{1}{1-p} = 0$$

נציב את Q ונחשב את הפונקציה Q.

$$p^* = \frac{\sum_{t=1}^n w_{t1}}{n}$$

כאשר נתון את  $\lambda_1$  ו-Q:

$$\frac{\partial}{\partial \lambda_1} \sum_{t=1}^n w_{t1} (\log \lambda_1 - \lambda_1 x_t) = \sum_{t=1}^n w_{t1} \cdot \frac{1}{\lambda_1} - w_{t1} \cdot x_t = 0$$

נציב את Q:

$$\lambda_1^* = \frac{\sum_{t=1}^n w_{t1}}{\sum_{t=1}^n w_{t1} x_t}$$

כאשר נתון את  $\lambda_2$  ו-Q:

$$\lambda_2^* = \frac{\sum_{t=1}^n w_{t2}}{\sum_{t=1}^n w_{t2} x_t}$$



2)  $\delta \in \mathbb{E}$

אזרחי מ"ב: Auxiliary

$$Q(\theta, \theta^*) = \sum_{i=1}^n \sum_{j=1}^3 P(y_i = j | x_i; \theta) \cdot \log p(x_i, y_i = j; \theta^*) =$$

$$= \sum_{i=1}^n \sum_{j=1}^3 P(y_i = j | x_i; \theta) \log\left(\frac{1}{3} \cdot \mathcal{N}(y_i, \mu, 1)\right)$$

המשקל  $w_{ji}$  יהיו כהסתברות של  $y_i = j$  בהינתן  $x_i$ .  
 נניח  $\mu = 1, 2, 3$

$$w_{1i} = \frac{P(x_i | y_i = 1; \theta) \cdot P(y_i = 1; \theta)}{\sum_{j=1}^3 P(x_i | y_i = j; \theta) \cdot P(y_i = j; \theta)} = \frac{\mathcal{N}(\mu, 1)}{\mathcal{N}(\mu, 1) + \mathcal{N}(2\mu, 1) + \mathcal{N}(3\mu, 1)}$$

ובאופן כללי  $w_{2i}$  ו  $w_{3i}$

כאשר  $\mu$  הוא הממוצע של  $y_i$  ו  $\mu \in (0, 1)$

$$\frac{\partial}{\partial \mu} \left( \sum_{i=1}^n \sum_{j=1}^3 w_{ji} \log\left(\frac{1}{3} \cdot \left(\frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2} \cdot (x_i - j\mu)^2\right)\right)\right) \right) =$$

$$\sum_{i=1}^n \sum_{j=1}^3 w_{ji} j (x_i - j\mu) = 0$$

לכן

$$\mu = \frac{\sum_{i=1}^n x_i w_{1i} + 2 \sum_{i=1}^n x_i w_{2i} + 3 \sum_{i=1}^n x_i w_{3i}}{\sum_{i=1}^n w_{1i} + 4 \sum_{i=1}^n w_{2i} + 9 \sum_{i=1}^n w_{3i}}$$

$$P(y=1|x,z) = \frac{P(z|y=1,x) \cdot P(y=1|x)}{P(z|x)} \quad \text{--- (3)}$$

$$\frac{\mathcal{N}(\mu, 1) \cdot \sigma(\omega x + b)}{(1 - \sigma(\omega x + b)) \cdot \mathcal{N}(0, 1) + \sigma(\omega x + b) \cdot \mathcal{N}(\mu, 1)}$$

הנחת  $p(z|y=1, x) = p(z|y=1)$  - e  
 הנתון  $p(z|y=1, x) = p(z|y=1)$  - e

• לפי איך נקראת

• נ"ל נמצא כי המודל הוא ליניארי. נשאלת השאלה: האם המודל הזה יכול ללמוד את הנתונים? כלומר, האם המודל הזה יכול ללמוד את הנתונים? כלומר, האם המודל הזה יכול ללמוד את הנתונים?

$$L(\theta) = \sum_{t=1}^n \log P(x_t, y_t, z_t; \theta) = \sum_{t=1}^n \log [P(z_t | y_t, x_t; \theta_z) P(y_t | x_t; \theta_y) P(x_t)] =$$

$$= \sum_{t=1}^n \log P(z_t | y_t; \mu) + \sum_{t=1}^n \log P(y_t | x_t; \omega, b) + \sum_{t=1}^n P(x_t)$$

כאשר נוכל למצוא את המודל הזה, נמצא כי המודל הזה יכול ללמוד את הנתונים.

$$|S_i| = |\{x_t | y_t = 1\}| = m \quad \text{י"י}$$

$$\sum_{t \in S_i} \frac{\partial}{\partial \mu} \log \left[ \frac{1}{\sqrt{2\pi}} \cdot \exp\left(-\frac{1}{2}(z_t - \mu)^2\right) \right] = \sum_{t \in S_i} z_t - \mu = \sum_{t \in S_i} z_t - \sum_{t \in S_i} \mu = 0$$

$$\Rightarrow \mu^* = \frac{\sum_{t \in S_i} z_t}{m}$$

כאשר ננסה למצוא את המודל הזה, נמצא כי המודל הזה יכול ללמוד את הנתונים.

$$P(y_t | x_t; \omega, b) = \sigma(\omega x + b)^{y_t} (1 - \sigma(\omega x + b))^{1-y_t}$$

כיוון שאין פתרון סגור ונאלץ להשתמש בשיטות מסוג Gradient Descent, נשתמש בשיטת Gradient Descent כדי למצוא את המודל הזה. נשתמש בשיטת Gradient Descent כדי למצוא את המודל הזה. נשתמש בשיטת Gradient Descent כדי למצוא את המודל הזה.



• זהו E

$$w_{ti} = P(y_t = i | x_t, z_t; \theta_0)$$

ההסתברות של  $y_t$  להיות  $i$  בהינתן  $x_t$  ו- $z_t$  תלוי ב- $\theta_0$ .  
 נרצה למצוא את  $\theta_0$  שממקסם את הפונקציה:

$$Q(\theta, \theta_0) = \sum_{t=1}^n \sum_{i \in \{0,1\}} w_{ti} \log p(x_t, y_t, z_t; \theta) =$$

$$\sum_{t=1}^n \sum_{i \in \{0,1\}} w_{ti} \cdot \log [P(x_t | y_t, z_t) P(z_t | y_t, \mu) P(y_t | w, b)]$$

זהו M

כדי למצוא את  $\theta_0$  נשתמש בשיטת הגרדיאנט.

$$\hat{\mu} = \frac{\partial Q}{\partial \mu}$$


$$\hat{b} = \frac{\partial Q}{\partial b}$$

$$\hat{w} = \frac{\partial Q}{\partial w}$$

4. (b) הרבטים שהתקבלו כאשר היה שימוש ב-20 פרזנטואר  
 היו לא מצידיים כדור המקדים. רצמנה:  
 $\mu = (-9.3, 4.6, 9.1)$   
 $\sigma^2 = (0.5, 0.78, 0.76)$   
 $\alpha = (0.15, 0.3, 0.55)$

כאשר מצויים לא מספר הפרזנטואר ל-200 הרבטים שהתקבלו  
 קבוצים גרבה "רב לא מצידיים" זה קורה ככל שאם המצגם  
 עולה, ההסתברות שהממוצע שלו יסב מהר יותר, קצת  
 (חוק המסכים הצדדים).

(c) עמדת ניסוי זה ניתן לכאורה שזם הרבטים המשוערים  
 אלס הנכח-א-ר עתים שונים מניסוי עניסוי. זה מצביע  
 על כך EM-ע מוצג מקסימום עוקרי של הנכח-א-ר, ועל  
 מקסימום צדדי (שהוא לא ריב כנראה).



```
# Vadim Litvinov
import collections
from random import choices
from random import gauss
from math import sqrt
from matplotlib import pyplot as plt
import numpy as np
import seaborn as sns

K = 3
N = 200
N_ITER = 1000
PARAMETERS = [[-1.0, sqrt(2)],
               [4.0, sqrt(3)],
               [9.0, sqrt(1)]]
WEIGHTS = [0.2, 0.3, 0.5]
EPS = 1e-8

def PDF(data, means, variances):
    return 1/(np.sqrt(2 * np.pi * variances) + EPS) * np.exp(-1/2 * (np.square(data - means)
    / (variances + EPS)))

def getRandomParams(n):
    x = np.random.normal(0, 1, size=(n, n))
    return np.dot(x, x.transpose())

def emGmm(data, k, n_iter):
    weights = np.ones((k, 1)) / k # shape=(k, 1)
    means = np.random.choice(data, k)[:, np.newaxis] # shape=(k, 1)
    print('starting point means: ', means)
    #variances = np.random.random_sample(size=k)[:, np.newaxis] # shape=(k, 1)
    data = np.repeat(data[np.newaxis, :], k, 0) # shape=(k, n)
    vars = np.expand_dims(np.mean(np.square(data - means), axis=1), -1)
    p_list = []
    for step in range(n_iter):
        p = PDF(data, means, vars)
        b = p * weights
        denom = np.expand_dims(np.sum(b, axis=0), 0) + EPS
        b = b / denom
        p_list.append(np.sum(np.log(np.amax(b, axis=0))))
    #print('average likelihood: ', np.sum(np.amax(b, axis=0)) / (N))
```



```

        means_n = np.sum(b * data, axis=1)
        means_d = np.sum(b, axis=1) + EPS
        means = np.expand_dims(means_n / means_d, -1)
        vars = np.sum(b * np.square(data - means), axis=1) / means_d
        vars = np.expand_dims(vars, -1)
        weights = np.expand_dims(np.mean(b, axis=1), -1)
    print('log likelihood: ', np.sum(np.log(np.amax(b, axis=0))))
    #plt.plot(range(n_iter), p_list)
    #plt.show()
    return means, vars, weights

if __name__ == '__main__':
    sampled_gaussians = choices([0, 1, 2], WEIGHTS, k=N)
    print(collections.Counter(sampled_gaussians))
    sampled_gaussians = collections.Counter(sampled_gaussians)
    #sampled_gaussians = list(sampled_gaussians.items())
    samples = np.empty([0, N])
    for i in range(len(sampled_gaussians)):
        #samples.append(gauss(PARAMETERS[sampled_gaussians[i]][0],
        #                      PARAMETERS[sampled_gaussians[i]][1]))
        mu_i = PARAMETERS[i][0]
        sigma_i = PARAMETERS[i][1]
        sample_size = sampled_gaussians[i]
        samples = np.concatenate((samples, np.random.normal(mu_i, sigma_i,
size=sampled_gaussians[i])), axis=None)
    samples = np.asarray(samples, dtype=np.float32)
    #check weights is properly working
    #print(sampled_gaussians.count(0), sampled_gaussians.count(1),
sampled_gaussians.count(2))
    #print(sampled_gaussians)
    print('sampled_gaussians: ', sampled_gaussians)
    print('samples: ', samples)
    #plt.hist(samples, bins=200)
    #plt.show()
    #random_params = initializeParams()

    for i in range(10):
        means, variances, weights = emGmm(samples, K, N_ITER)
        print('means: ', means, 'variances: ', variances, 'weights: ', weights, '\n')

```